

参考答案

第一章（绪论）

1，什么是有监督模式识别？

有训练样本，通过已知样本类别属性的训练样本来训练分类器，得到一个在相应优化准则下的最优分类器，再利用这个分类器将新的样本分类，得到该样本的类别属性。

2，什么是非监督模式识别？


没有已知样本类别属性的训练样本，需要根据数据本身之间的属性对数据进行分类，相似相近的数据分在同一类；不相似或不相近的数据分在不同的类中。

3，什么是特征？什么是特征向量？

特征：反映事物的本质属性的量。

特征向量：所有特征组合起来形成的向量。

4，画出典型的有监督模式识别系统的基本组成框图。



- **数据获取：**主要是由不同形式的传感器构成，实现信息获取与信息在不同媒体之间的转换。
- **预处理：**主要是指去除所获取信息中的噪声，增强有用的信息，及一切必要的使信息纯化的处理过程。
- **特征选择和提取：**将所获取的原始量测数据转换成能反映事物本质，并将其最有效分类的特征表示。
- **分类器设计：**将该特征空间划分成由各类占据的子空间，确定相应的决策分界，如：分界面方程，决策域等。
- **分类决策：**是指分类器在分界形式及其具体参数都确定后，对待分类样本进行分类决策的过程

5, 什么是模式的紧致性?

反映模式在特征空间的分布方式的量。同类样本比较集中, 不同类别的样本比较分散, 分界面干净利索, 则是紧致性好。

第二章 (贝叶斯决策理论) 作业

1, 最小错误率贝叶斯决策的优化准则是什么? 由此设计的分类器是否是最优的分类器? 若是, 是在什么条件下的最优分类器?

最小错误率贝叶斯决策的优化准则是平均错误率, 按此准则设计的分类器是在平均错误率最小意义上的最优分类器。

2, 最小风险贝叶斯决策的优化准则是什么? 由此设计的分类器是否是最优的分类器? 若是, 是在什么条件下的最优分类器?

最小风险贝叶斯决策的优化准则是平均风险, 按此准则设计的分类器是在平均风险最小意义上的最优分类器。

3, 什么是分界面? 什么是决策域? 什么是决策面方程?

决策域: 各类别在特征空间内所占的区域。决策域的边界面就是决策面, 在数学上用解析形式表示成决策面方程。

4, 写出最小错误率贝叶斯决策的几种判别函数, 以及分界面方程。

1) 判别函数: $g_i(X) = P(\omega_i | X), i = 1, 2, \dots, C$

第 i 类与第 j 类相邻, 则分界面方程为: $P(\omega_i | X) = P(\omega_j | X)$

2) 判别函数: $g_i(X) = p(X | \omega_i)P(\omega_i), i = 1, 2, \dots, C$

第 i 类与第 j 类相邻, 则分界面方程为: $p(X | \omega_i)P(\omega_i) = p(X | \omega_j)P(\omega_j)$

3) 似然比: $g(x) = \frac{p(X | \omega_1)}{p(X | \omega_2)}$, 分界面方程: $\frac{p(X | \omega_1)}{p(X | \omega_2)} = \frac{P(\omega_2)}{P(\omega_1)}$

4) 对数似然比: $h(x) = -\ln p(X | \omega_1) + \ln p(X | \omega_2)$

分界面方程: $-\ln p(X | \omega_1) + \ln p(X | \omega_2) = \ln \frac{P(\omega_1)}{P(\omega_2)}$

5, 两类正态分布, 若满足:

1) $\Sigma_1 = \Sigma_2 = \sigma^2 I$, $P(\omega_1) = P(\omega_2)$, $\mu_1 \neq \mu_2$, I 是单位矩阵, 按最小错误率决策, 则分类器是何种类型的分类器? 分界面是什么样的?

最小(欧氏)距离分类器, 分界面是线性分界面。

2) $\Sigma_1 = \Sigma_2 \neq \sigma^2 I$, $P(\omega_1) = P(\omega_2)$, $\mu_1 \neq \mu_2$, I 是单位矩阵, 按最小错误率决策, 则分类器是何种类型的分类器? 分界面是什么样的?

最小(马氏)距离分类器, 分界面是线性分界面。

3) $\Sigma_1 = \Sigma_2 \neq \sigma^2 I$, $P(\omega_1) \neq P(\omega_2)$, $\mu_1 \neq \mu_2$, I 是单位矩阵, 按最小错误率决策, 则分类器是何种类型的分类器? 分界面是什么样的?

线性分类器, 分界面是线性分界面。

4) $\Sigma_1 \neq \Sigma_2$, 按最小错误率决策, 则分类器又是何种类型的分类器? 分界面是什么样的? 写出一维情况下的判别函数形式。

二次分类器, 分界面是二次分界面, 如双曲面, 抛物面等。

6、1) 对两类问题, 证明最小风险贝叶斯决策规则可表示为

$$\text{若 } \frac{p(X|\omega_1)}{p(X|\omega_2)} > \frac{\lambda_{12} - \lambda_{22}}{\lambda_{21} - \lambda_{11}} \frac{P(\omega_2)}{P(\omega_1)} \quad \text{则 } X \in \omega_1 \quad (\text{一般, } \lambda_{11} < \lambda_{21} \quad \lambda_{22} < \lambda_{12})$$

2) 若 $\lambda_{11} = \lambda_{22} = 0$; $\lambda_{12} = \lambda_{21}$, 证明此时最小风险决策等价于最小错误率决策

解: 1) 最小风险贝叶斯决策规则:

$$\text{条件风险 } R(\alpha_i | X) = \sum_{j=1}^c \lambda(\alpha_i, \omega_j) P(\omega_j | X) = \sum_{j=1}^c \lambda_{ij} P(\omega_j | X) \quad i = 1, 2, \dots, K$$

$$\text{决策规则: 若 } R(\alpha_j | X) = \min_{i=1, 2, \dots, K} R(\alpha_i | X), \text{ 则 } X \in \alpha_j$$

$$\text{对两类: } R(\alpha_1 | X) = \lambda_{11} P(\omega_1 | X) + \lambda_{12} P(\omega_2 | X)$$

$$R(\alpha_2 | X) = \lambda_{21} P(\omega_1 | X) + \lambda_{22} P(\omega_2 | X)$$

$$\text{决策规则: 若 } R(\alpha_1 | X) < R(\alpha_2 | X), \text{ 则 } X \in \alpha_1$$

$$\text{即: 若 } \lambda_{11} P(\omega_1 | X) + \lambda_{12} P(\omega_2 | X) < \lambda_{21} P(\omega_1 | X) + \lambda_{22} P(\omega_2 | X), \text{ 则 } X \in \alpha_1$$

$$\lambda_{21} P(\omega_1 | X) - \lambda_{11} P(\omega_1 | X) > \lambda_{12} P(\omega_2 | X) - \lambda_{22} P(\omega_2 | X), \text{ 则 } X \in \alpha_1$$
$$(\lambda_{21} - \lambda_{11}) P(\omega_1 | X) > (\lambda_{12} - \lambda_{22}) P(\omega_2 | X)$$

由贝叶斯公式: $P(\omega_i | X) = \frac{p(X | \omega_i)P(\omega_i)}{p(X)}$, $i = 1, 2$, 代入上式, 得

若 $(\lambda_{21} - \lambda_{11}) \frac{p(X | \omega_1)P(\omega_1)}{p(X)} > (\lambda_{12} - \lambda_{22}) \frac{p(X | \omega_2)P(\omega_2)}{p(X)}$, 则 $X \in \alpha_1$

即: 若 $(\lambda_{21} - \lambda_{11}) p(X | \omega_1)P(\omega_1) > (\lambda_{12} - \lambda_{22}) p(X | \omega_2)P(\omega_2)$

因为, 正确决策带来的损失 (风险) < 错误正确决策带来的损失 (风险), 即

$$\lambda_{11} < \lambda_{21} \quad \lambda_{22} < \lambda_{12}, \text{ 或 } \lambda_{21} - \lambda_{11} > 0, \quad \lambda_{12} - \lambda_{22} > 0$$

因此, 上式可化为:

若 $\frac{p(X | \omega_1)}{p(X | \omega_2)} > \frac{\lambda_{12} - \lambda_{22}}{\lambda_{21} - \lambda_{11}} \frac{P(\omega_2)}{P(\omega_1)}$, 则 $X \in \alpha_1$

命题得证。

(2) 将已知条件代入上式, 得

若: $\frac{p(X | \omega_1)}{p(X | \omega_2)} > \frac{P(\omega_2)}{P(\omega_1)}$, 则 $X \in \alpha_1$ 。此即最小错误率决策的决策规则

7、写出两类情况下最小风险贝叶斯决策的判别函数和决策面方程。

对两类: $R(\alpha_1 | X) = \lambda_{11}P(\omega_1 | X) + \lambda_{12}P(\omega_2 | X)$

$$R(\alpha_2 | X) = \lambda_{21}P(\omega_1 | X) + \lambda_{22}P(\omega_2 | X)$$

决策规则: 若 $R(\alpha_1 | X) < R(\alpha_2 | X)$, 则 $X \in \alpha_1$

判别函数: $g_1(X) = R(\alpha_1 | X) = \lambda_{11}P(\omega_1 | X) + \lambda_{12}P(\omega_2 | X)$

$$g_2(X) = R(\alpha_2 | X) = \lambda_{21}P(\omega_1 | X) + \lambda_{22}P(\omega_2 | X)$$

决策规则: 若 $g_1(X) < g_2(X)$, 则 $X \in \alpha_1$

决策面方程: $g_1(X) = g_2(X)$

或: $\lambda_{11}P(\omega_1 | X) + \lambda_{12}P(\omega_2 | X) = \lambda_{21}P(\omega_1 | X) + \lambda_{22}P(\omega_2 | X)$

7、假设两类(ω_1 和 ω_2)的先验概率分别为 $P(\omega_1)=0.9$, $P(\omega_2)=0.1$ 。类条件概率密度分布曲线为 $p(x|\omega_1)$, $p(x|\omega_2)$, 两者均满足正态分布, 方差相同, 均为 1, 均值分别是 -1, 和 1。

1) 写出按最小错误率决策时的负对数似然比决策规则。

2) 根据 1) 写出判别函数及决策面方程。

解：最小错误率决策时的负对数似然比决策规则：

$$\text{若： } h(x) = -\ln[l(x)] = -\ln p(X | \omega_1) + \ln p(X | \omega_2) < \ln \frac{P(\omega_1)}{P(\omega_2)}$$

$$\text{或若： } g(x) = h(x) - \ln \frac{P(\omega_1)}{P(\omega_2)} = -\ln p(X | \omega_1) + \ln p(X | \omega_2) - \ln \frac{P(\omega_1)}{P(\omega_2)} < 0$$

$$\text{则： } X \in \omega_1$$

对本题：

决策规则：

$$\text{若： } g(x) = 2x - \ln 9 < 0 \quad \text{则： } X \in \omega_1$$

1) 最小错误率决策时的负对数似然比决策规则：

$$\text{若： } h(x) = -\ln[l(x)] = -\ln p(X | \omega_1) + \ln p(X | \omega_2) < \ln \frac{P(\omega_1)}{P(\omega_2)}$$

$$\text{或若： } g(x) = h(x) - \ln \frac{P(\omega_1)}{P(\omega_2)} = -\ln p(X | \omega_1) + \ln p(X | \omega_2) - \ln \frac{P(\omega_1)}{P(\omega_2)} < 0$$

$$\text{则： } X \in \omega_1$$

由给定已知条件，可以写出：

$$p(x | \omega_1) = \frac{1}{\sqrt{2\pi}} \exp \left[-\frac{(x+1)^2}{2} \right]; \quad p(x | \omega_2) = \frac{1}{\sqrt{2\pi}} \exp \left[-\frac{(x-1)^2}{2} \right]$$

因此：

$$g(x) = -\ln p(X | \omega_1) + \ln p(X | \omega_2) - \ln \frac{P(\omega_1)}{P(\omega_2)}$$

$$= \frac{(x+1)^2}{2} - \frac{(x-1)^2}{2} - \ln \frac{0.9}{0.1}$$

$$= 2x - \ln 9$$

决策规则：

$$\text{若： } g(x) = 2x - \ln 9 < 0 \quad \text{则： } X \in \omega_1$$

2) 由 1) 有

$$\text{判别函数： } g(x) = 2x - \ln 9$$

决策面方程：

$$g(x) = 2x - \ln 9 = 0$$

$$x = \ln 3$$

8、1) 写出最小距离分类器的判别函数及决策规则。

2) 考虑一个两维的两类分类问题，其先验概率相同，类条件概率均服从正态分布，各类的均值及协方差矩阵分别为

$$\mu_1 = [3, 6]^T, \quad \Sigma_1 = \begin{bmatrix} 1/2 & 0 \\ 0 & 1/2 \end{bmatrix}; \quad \mu_2 = [3, -2]^T, \quad \Sigma_2 = \begin{bmatrix} 1/2 & 0 \\ 0 & 1/2 \end{bmatrix}$$

若按最小错误率贝叶斯决策，求其决策面方程。

1)

$$g_i(X) = \|X - \mu_i\|^2$$

$$\text{if } g_j(X) = \min \{g_i(X), i = 1, 2, \dots, C\}$$

$$\text{then } X \in \omega_j$$

2) 满足正态分布，协方差矩阵相等且是单位阵的倍数，因此，最小错误率贝叶斯决策即是最小距离分类器，因此，分界面方程为：

$$\|X - \mu_1\|^2 = \|X - \mu_2\|^2$$

$$\|X - [3, 6]^T\|^2 = \|X - [3, -2]^T\|^2$$

$$\text{设 } X = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

则

$$\|[x_1, x_2]^T - [3, 6]^T\|^2 = \|[x_1, x_2]^T - [3, -2]^T\|^2$$

$$\|[x_1 - 3, x_2 - 6]^T\|^2 = \|[x_1 - 3, x_2 + 2]^T\|^2$$

$$x_2 = 2$$

9、二维样本服从正态分布，两类先验概率相等，均值向量分别为

$\mu_1 = [1, 0]^T$, $\mu_2 = [-1, 0]^T$, 若 $\Sigma_1 = \Sigma_2 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$, 写出负对数似然比决策规则

解：由给定已知条件，可以写出：

$$p(X | \omega_1) = \frac{1}{2\pi\sqrt{|\Sigma_1|}} \exp \left[-\frac{(X - \mu_1)^T \Sigma_1^{-1} (X - \mu_1)}{2} \right];$$

$$p(X | \omega_2) = \frac{1}{2\pi\sqrt{|\Sigma_2|}} \exp \left[-\frac{(X - \mu_2)^T \Sigma_2^{-1} (X - \mu_2)}{2} \right]$$

因此：

$$\begin{aligned} g(X) &= -\ln p(X | \omega_1) + \ln p(X | \omega_2) - \ln \frac{P(\omega_1)}{P(\omega_2)} \\ &= -\left[-\frac{1}{2} (X - \mu_1)^T \Sigma_1^{-1} (X - \mu_1) \right] - \ln \frac{1}{2\pi\sqrt{|\Sigma_1|}} \\ &\quad + \left[-\frac{1}{2} (X - \mu_2)^T \Sigma_2^{-1} (X - \mu_2) \right] + \ln \frac{1}{2\pi\sqrt{|\Sigma_2|}} - \ln \frac{P(\omega_1)}{P(\omega_2)} \\ &= \left[\frac{1}{2} (X - \mu_1)^T \Sigma_1^{-1} (X - \mu_1) - \frac{1}{2} (X - \mu_2)^T \Sigma_2^{-1} (X - \mu_2) \right] + \ln \frac{|\Sigma_1|}{|\Sigma_2|} - \ln \frac{P(\omega_1)}{P(\omega_2)} \\ &= \left[\frac{1}{2} (X - \mu_1)^T \Sigma_1^{-1} (X - \mu_1) - \frac{1}{2} (X - \mu_2)^T \Sigma_2^{-1} (X - \mu_2) \right] + \ln \frac{|\Sigma_1|}{|\Sigma_2|} \end{aligned}$$

决策规则： 若 $g(x) < 0$ 则 $X \in \omega_1$

由题意， $\Sigma_1 = \Sigma_2 = I$ ，因此，

$$g(X) = \left[\frac{1}{2} (X - \mu_1)^T (X - \mu_1) - \frac{1}{2} (X - \mu_2)^T (X - \mu_2) \right]$$

故有决策规则：

$$g(X) = \left[\frac{1}{2} (X - \mu_1)^T (X - \mu_1) - \frac{1}{2} (X - \mu_2)^T (X - \mu_2) \right] < 0 \Rightarrow X \in \omega_1$$

$$\text{或: } \|X - \mu_1\|^2 < \|X - \mu_2\|^2 \Rightarrow X \in \omega_1$$

(即最小距离分类器)

设 $X = [x \ y]^T$ ，则有

$$(x-1)^2 + y^2 < (x+1)^2 + y^2$$

$$x > 0 \Rightarrow X \in \omega_1$$

10, 有 8 个人, 其中男生和女生各 4 人, 他(她)们的特征:[身高, 体重, 鞋码] 如下表所示, 设各特征相互独立, 均匀分布。现有一人, 其特征为:[高, 重, 大], 按朴素贝叶斯方法判断该生的性别。

编号	身高	体重	鞋码	性别
1	高	重	大	男
2	高	重	大	男
3	中	中	大	男
4	中	中	中	男
5	中	轻	小	女
6	中	轻	小	女
7	中	中	中	女
8	矮	中	中	女

解: 由题课件, 男女两类的先验概率为: $P(\text{男})=P(\text{女})=4/8=0.5$

$$P(\text{男})p(\text{高, 重, 大}|\text{男})=P(\text{男})p(\text{高}|\text{男}) p(\text{重}|\text{男}) p(\text{大}|\text{男})$$

$$=0.5*2/4*2/4*3/4=1.5/16$$

$$P(\text{女})p(\text{高, 重, 大}|\text{女})=P(\text{女})p(\text{高}|\text{女}) p(\text{重}|\text{女}) p(\text{大}|\text{女})$$

$$=0.5*0/4*0/4*0/4=0$$

是男生

第三章作业

1, 写出 Fisher 准则。Fisher 准则是基于什么原理提出的? 指出按 Fisher 准则求解权向量, 重要的是权向量的方向, W 的比例因子对判决结果无影响。若权向量增加 k 倍, 则阈值权会有何变化?

准则

$$J_F(W) = \frac{(\tilde{m}_1 - \tilde{m}_2)^2}{\tilde{S}_1^2 + \tilde{S}_2^2} = \frac{W^T S_b W}{W^T S_w W}$$

这里, S_b, S_w 是原高维空间的总的类间和类内离散度矩阵。 m_1, m_2 是投影后

一维空间两类的均值, S_1, S_2 则是投影后一维空间两类的类内离散度

Fisher 准则的提出主要以下两点:

- (1) 两类样本投影后的均值之差尽可能大些
- (2) 类内样本投影后的离散程度尽可能小

假设 W 乘一比例因子 α , αW , 经过投影后得到 $y = \alpha W^T X$ 。相当于对所有样本乘以一个比例因子, 所以对判别结果没有影响。此外, 易证:

$$J_F(kW) = \frac{(kW)^T S_b (kW)}{(kW)^T S_w (kW)} = \frac{W^T S_b W}{W^T S_w W} = J_F(W), \quad k \text{ 是常数。}$$

说明, 按 Fisher 准则求解权向量, 重要的是权向量的方向, W 的比例因子对判决结果无影响。其准则也无变化。

阈值权 W_0 的取值则会受 W 的影响。因为: 阈值权 W_0 由投影后一维数据 $y = W^T X$ 确定, W 放大 k 倍, 则投影后数据也会放大 k 倍, 阈值相应增加 k 倍。

(3) 证明在正态等协方差条件下, Fisher 线性判别等价于贝叶斯判别。

在正态等协方差的条件下, 判别函数 $g(x) = w^T x + w_0$ 中 $w = \Sigma^{-1}(u_1 - u_2)$, 在 Fisher 线性判别中最优投影方向为:

$$S_w = N_1 \Sigma_1 + N_2 \Sigma_2 = (N_1 + N_2) \Sigma$$

$$w = (N_1 + N_2)^{-1} \Sigma^{-1} (u_1 - u_2)。$$

忽略常数项, $S_w = \Sigma^{-1}(u_1 - u_2)$
可见, 两者等价

(4) 写出感知准则函数方法的优化准则。感知准则函数采用什么优化方法求解权向量?

感知准则函数使用增广样本向量 a 与增广权向量 y , 优化准则为:

$$J_p(a) = \sum_{y \in y^k} (-a^T y) \geq 0,$$

这里, y_k 表示被 a 错分类的规范化增广样本集
采用梯度下降法求解

(5) 什么叫线性可分样本集？对于线性可分样本集，其解向量是否唯一？

用线性分类器可以无错误率分开的样本称为线性可分样本集
解向量不唯一，有解区

(6) 画出最近邻法，K 近邻法的算法流程图。

略。见课件

(7) 近邻法有何优缺点？

优点：算法简单，在样本数趋于无穷大时分类错误率小，接近最小错误率贝叶斯决策的错误率。

缺点：计算量大，存储量大

(8) 剪辑近邻法和压缩近邻法提出的目的是什么？剪辑近邻法去掉的是哪些样本？压缩近邻法去掉的又是哪些样本？两者的性能如何？

目的是减小计算量和存储量

剪辑近邻法是去掉在两类边界附近的样本点。错误率性能有所改善，但是，样本数减少有限，计算量和存储量的改善有限。

压缩近邻法一般是在剪辑近邻法之后使用（边界干净），去掉的是远离边界的样本，仅保留少量边界附近的样本，可以大大提高计算速度，减少存储量。

7、已知两类二维样本属于正态分布，先验概率相等，其均值向量、协方差矩阵如下：

$$\mu_1 = [-2, -2]^T, \quad \mu_2 = [2, 2]^T, \quad \Sigma_1 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad \Sigma_2 = \begin{bmatrix} 1 & 0 \\ 0 & 4 \end{bmatrix}$$

按 fisher 准则求解最优投影方向 W 。

$$\text{解：总的类内离散度矩阵： } S_w = \frac{1}{2}(\Sigma_1 + \Sigma_2) = \frac{1}{2} \left(\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} + \begin{bmatrix} 1 & 0 \\ 0 & 4 \end{bmatrix} \right) = \begin{bmatrix} 1 & 0 \\ 0 & 5/2 \end{bmatrix}$$

$$S_w^{-1} = \begin{bmatrix} 1 & 0 \\ 0 & 2/5 \end{bmatrix}$$

最优方向：

$$\begin{aligned} W^* &= S_w^{-1}(\mu_1 - \mu_2) = \begin{bmatrix} 1 & 0 \\ 0 & 2/5 \end{bmatrix} \left(\begin{bmatrix} -2 \\ -2 \end{bmatrix} - \begin{bmatrix} 2 \\ 2 \end{bmatrix} \right) \\ &= \begin{bmatrix} -4 \\ -8/5 \end{bmatrix} \end{aligned}$$

$$\text{归一化： } W^* = - \begin{bmatrix} 5/\sqrt{29} \\ 2/\sqrt{29} \end{bmatrix}$$

8、采用批处理感知器算法设计线性分类器 $g(X) = A^T X$ 对某两类线性可分样本集进行分类，样本总数为 N 个。假设在第 k 次迭代时，得到了增广权向量：

$A(k) = [-0.5 \ 1 \ 1]^T$ 。用该权向量对样本进行分类鉴别，前 $N-2$ 个都能正确分类，还剩样本 x_1 、 x_2 尚未鉴别， x_1 和 x_2 规范化后增广样本向量及其类别属性分别为：

$$X_1 = [1, 0.4, 0.05]^T, \quad X_1 \in \omega_1; \quad X_2 = [-1, -0.2, 0.75]^T, \quad X_2 \in \omega_2$$

若迭代步长 $\rho(k) = \rho = 0.7$ ，求第 $k+1$ 次迭代时的增广权向量 $A(k+1)$ 。

迭代公式：
$$a(k+1) = a(k) - \rho_k \nabla J_p = a(k) + \rho_k \sum_{y^k} y^k, \quad \rho_k > 0$$

y^k 是第 k 次迭代时的错分样本集

对样本 x_1 ， $a^T(k) X_1 = [-0.5 \ 1 \ 1][1, 0.4, 0.05]^T = -0.05 < 0$ ，错分

对样本 x_2 ， $a^T(k) X_2 = [-0.5 \ 1 \ 1][-1, -0.2, 0.75]^T = 1.05 > 0$ ，正确分类

因此

$$\begin{aligned} A(k+1) &= A(k) + \rho_k X_1 \\ &= [-0.5 \ 1 \ 1]^T + 0.7[1, 0.4, 0.05]^T \\ &= [0.2 \ 1.28 \ 1.035]^T \end{aligned}$$

9、有 7 个 2 维向量组成的训练样本： $x_1=[0, -1]^T$ ， $x_2=[0, 1]^T$ ， $x_3=[1, 0]^T$ ；

$x_4=[0, 0]^T$ ， $x_5=[0, 2]^T$ ， $x_6=[-1, 0]^T$ ， $x_7=[0, -2]^T$ ；

前 3 个是 w_1 类，后 4 个是 w_2 类。

分别采用 1) 最近距离法；2) 最近邻法；3) 3-近邻法（K 近邻法中， $K=3$ ）

对样本 $X=[0.4, 0.4]^T$ 分类。

解：

解：1) 第 1 类均值： $m_1=(x_1+x_2+x_3)/2=[1/3, 0]^T$

第 2 类均值： $m_2=(x_4+x_5+x_6)/2=[0, 0]^T$

X 到 m_1 距离： $d_{01}=0.4055$

X 到 m_2 距离： $d_{02}=0.5657 > d_{01}$

故 X 是 w_1 类

2) 算该点到各点距离:

到 x_1 距离 $d_1 = 0.7211$

到 x_2 距离 $d_2 = 0.7211$

到 x_3 距离 $d_3 = 1.4560$


到 x_4 距离 $d_4 = 0.5657$

到 x_5 距离 $d_5 = 1.6492$

到 x_6 距离 $d_6 = 2.4331$

可见, x 的最近邻是 x_4 (是 w_2 类), 故 x 是 w_2 类。

3) 根据 2 的结果, 3 个近邻分别是 x_1, x_2, x_4 , 属于第 1 类的两点 (x_1, x_2), 因此, 决策为第 1 类, x 是 w_1 类。



第 4 章作业

1、什么是特征提取和特征选择? 特征提取和选择的目的是什么?

特征选择: 已有 D 维特征向量空间, $Y=\{y_1, y_2, \dots, y_D\}$, 从原有的 D 维特征空间, 删去一些

特征描述量, 从而得到精简后的特征空间。在这个特征空间中, 样本由 d 维的特征向量描述: $X=\{x_1, x_2, \dots, x_d\}$, $d < D$

特征提取: 找到一个映射关系: $A: Y \rightarrow X$, 使新样本特征描述维数比原维数降低。其中每个分量 x_i 是原特征向量各分量的函数。

特征提取和选择的目的是用于降维。

2、写出顺序前进法、顺序后退法的计算流程。

略。参见课件

3、有两类样本: $W_1: x_{11}=(0,0,0)^T, x_{12}=(1,0,0)^T, x_{13}=(1,0,1)^T, x_{14}=(1,1,0)^T$;

$W_2: x_{21}=(0,0,1)^T, x_{22}=(0,1,0)^T, x_{23}=(0,1,1)^T, x_{24}=(1,1,1)^T$

试利用判据 J_2 降低维数。

首先计算各类均值向量、协方差矩阵、类内离散度矩阵、类间离散度矩阵

1) 均值向量

$$\mu_1 = \frac{1}{4}(x_{11}+x_{12}+x_{13}+x_{14}) = \frac{1}{4} \begin{pmatrix} 3 \\ 1 \\ 1 \end{pmatrix}$$

$$\mu_2 = \frac{1}{4}(x_{21}+x_{22}+x_{23}+x_{24}) = \frac{1}{4} \begin{pmatrix} 1 \\ 3 \\ 3 \end{pmatrix} \quad \mu_1 - \mu_2 = \frac{1}{4} \begin{pmatrix} 2 \\ -2 \\ -2 \end{pmatrix}$$

2) 类内离散度矩阵、类间离散度矩阵

$$S_w = \sum_{i=1}^c P_i E_i[(x - \mu_i)(x - \mu_i)^T] \quad S_b = \sum_{i=1}^c P_i (\mu - \mu_i)(\mu - \mu_i)^T$$

$$\text{先验概率: } P_1 = P_2 = \frac{4}{8} = 0.5$$

$$S_w = \sum_{i=1}^c P_i E_i[(x - \mu_i)(x - \mu_i)^T] = \sum_{i=1}^c P_i \Sigma_i = \frac{1}{2}(\Sigma_1 + \Sigma_2)$$

$$\Sigma_1 = \frac{1}{4} \sum_{i=1}^4 (x_{1i} - \mu_1)(x_{1i} - \mu_1)^T = \frac{1}{16} \begin{bmatrix} 8 & -4 & -4 \\ -4 & 8 & 4 \\ -4 & 4 & 8 \end{bmatrix} = \Sigma$$

$$\Sigma_2 = \frac{1}{4} \sum_{i=1}^4 (x_{2i} - \mu_2)(x_{2i} - \mu_2)^T = \frac{1}{16} \begin{bmatrix} 8 & -4 & -4 \\ -4 & 8 & 4 \\ -4 & 4 & 8 \end{bmatrix} = \Sigma$$

$$S_w = \frac{1}{2}(\Sigma_1 + \Sigma_2) = \Sigma = \frac{1}{16} \begin{bmatrix} 8 & -4 & -4 \\ -4 & 8 & 4 \\ -4 & 4 & 8 \end{bmatrix}$$

$$S_b = \sum_{i=1}^c P_i (\mu - \mu_i)(\mu - \mu_i)^T$$

$$= \frac{1}{2} \left(\frac{\mu_1 + \mu_2}{2} - \mu_1 \right) \left(\frac{\mu_1 + \mu_2}{2} - \mu_1 \right)^T + \frac{1}{2} \left(\frac{\mu_1 + \mu_2}{2} - \mu_2 \right) \left(\frac{\mu_1 + \mu_2}{2} - \mu_2 \right)^T$$

$$= \frac{1}{4} (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T$$

$$S_w^{-1} S_b = \Sigma^{-1} (m_1 - m_2)(m_1 - m_2)^T = \frac{1}{16} \begin{bmatrix} 1 & -1 & -1 \\ -1 & 1 & 1 \\ -1 & 1 & 1 \end{bmatrix}$$

只有 1 个非零本征值。

非零本征值及本征向量：

$$\lambda = 3/4, \quad v = (-1, 1, 1)^T \rightarrow w = (-1, 1, 1)$$

$$\text{归一化: } w = (-1/\sqrt{3}, 1/\sqrt{3}, 1/\sqrt{3})^T$$

4、已知两类样本，其协方差矩阵及均值

$$\Sigma_1 = \Sigma_2 = \frac{1}{16} \begin{bmatrix} 3 & 1 & 1 \\ 1 & 3 & -1 \\ 1 & -1 & 3 \end{bmatrix}, \quad \mu_1 = \frac{1}{4} [3 \quad 1 \quad 1]^T, \quad \mu_2 = \frac{1}{4} [1 \quad 3 \quad 3]^T$$

总的类内离散度

$$S_w = \frac{1}{2} (\Sigma_1 + \Sigma_2) = \frac{1}{16} \begin{bmatrix} 3 & 1 & 1 \\ 1 & 3 & -1 \\ 1 & -1 & 3 \end{bmatrix}$$

已知其本征值矩阵和本征向量矩阵为，

$$\Lambda = \begin{bmatrix} 1/8 & 0 & 0 \\ 0 & 1/2 & 0 \\ 0 & 0 & 1/2 \end{bmatrix}, \quad U = \begin{bmatrix} -1/\sqrt{3} & -1/\sqrt{42} & 3/\sqrt{14} \\ -1/\sqrt{3} & -5/\sqrt{42} & 1/\sqrt{14} \\ 1/\sqrt{3} & 4/\sqrt{42} & 2/\sqrt{14} \end{bmatrix}$$

采用 K-L 变换的从类平均向量中提取判别信息的方法将数据降到 1 维，求变换向量

解：1) 由均值向量求出类间离散度矩阵：

$$S_b = \frac{1}{2} [\mu_1 - \mu_2][\mu_1 - \mu_2]^T = \begin{bmatrix} 1/8 & -1/8 & -1/8 \\ -1/8 & 1/8 & 1/8 \\ -1/8 & 1/8 & 1/8 \end{bmatrix}$$

3) 由类内离散度矩阵进行 KL 变换，得到其本征值矩阵及本征向量矩阵（已给定）

$$\Lambda = \begin{bmatrix} 1/8 & 0 & 0 \\ 0 & 1/2 & 0 \\ 0 & 0 & 1/2 \end{bmatrix},$$

$$U = \begin{bmatrix} -1/\sqrt{3} & -1/\sqrt{42} & 3/\sqrt{14} \\ -1/\sqrt{3} & -5/\sqrt{42} & 1/\sqrt{14} \\ 1/\sqrt{3} & 4/\sqrt{42} & 2/\sqrt{14} \end{bmatrix}$$

由 U 可得三个坐标：

$$u_1 = \begin{bmatrix} -1/\sqrt{3} \\ -1/\sqrt{3} \\ 1/\sqrt{3} \end{bmatrix}, u_2 = \begin{bmatrix} -1/\sqrt{42} \\ -5/\sqrt{42} \\ 4/\sqrt{42} \end{bmatrix}, u_3 = \begin{bmatrix} 3/\sqrt{14} \\ 1/\sqrt{14} \\ 2/\sqrt{14} \end{bmatrix}$$

$$\lambda_1 = 1/8; \quad \lambda_2 = 1/2; \quad \lambda_3 = 1/2$$

各坐标方向上判据

$$J_1 = \frac{u_1^T S_b u_1}{\lambda_1} = 1/3$$

$$J_2 = \frac{u_2^T S_b u_2}{\lambda_2} = 0$$

$$J_3 = \frac{u_3^T S_b u_3}{\lambda_3} = 0$$

可见，在 u_2, u_3 坐标上，无可分性。因此，可降到 1 维。

$$W = u_1 = \begin{bmatrix} -1/\sqrt{3} \\ -1/\sqrt{3} \\ 1/\sqrt{3} \end{bmatrix}$$

第 5 章作业

1， 基于模型的方法（基于概率分布的直接聚类方法）与间接的聚类算法各有什么特点？

基于模型的方法：

优点：样本数多时，反映数据的概率结构，结果能反映数据构造的真实情况
缺点：

- 1) 要对概率密度函数进行估计，计算的工作量大。
- 2) 在进行概率估计时要选定一些参数，因此估计的结果也会受到参数选择的较大影响。
- 3) 是在有噪声的情况下，具有局部最大值的概率密度函数的峰点都会发生变化，从而不能正确反映数据中的单峰子集数。

4) 样本数较少的情况下, 由于没有可能对概率密度函数进行估计。这种方法完全失去意义。

间接的动态聚类算法:

优点: 一般情况下计算效率很高

主要缺点:

选定的模型常常不能反映数据的概率结构, 因此用这些方法得到的结果不能反映数据构造的真实情况。只有通过选择各种各样的核函数以及分析这些核函数所得到的聚类结果来部分地解决这个问题。

分级聚类算法: 样本数较少的情况下是特别有用

2、K 均值聚类能否自动得到合理的聚类数目?

不能。

3、1) 写出 K 均值聚类的最小误差平方和准则。

2) 现有 4 个样本: $x_1=[4,5]^T$, $x_2=[1,4]^T$, $x_3=[0,1]^T$, $x_4=[5,0]^T$; 将其聚成两类, 若有如下 3 种聚类:

- (1) $\omega_1=\{x_1, x_2\}$; $\omega_2=\{x_3, x_4\}$
- (2) $\omega_1=\{x_1, x_4\}$; $\omega_2=\{x_2, x_3\}$
- (3) $\omega_1=\{x_1, x_2, x_3\}$; $\omega_2=\{x_4\}$

按 K 均值聚类的最小平方误差和准则, 哪种聚类最好?

解: 计算每种聚类的误差平方和

$$J=\sum_{i=1}^C \sum_{j=1}^{N_i} \|X_j - m_i\|^2, \quad m_i \text{ 是第 } i \text{ 类均值向量, } X_j \text{ 是第 } i \text{ 类的样本}$$

然后比较大小, 最小者最好。可算得第 3 种聚类的 J 最小, 因此, 第 3 种聚类最好

详细计算过程如下:

误差平方和

$$J=\sum_{i=1}^C \sum_{j=1}^{N_i} \|X_j - m_i\|^2, \quad m_i \text{ 是第 } i \text{ 类均值向量, } X_j \text{ 是第 } i \text{ 类的样本}$$

$$(1) \quad m_1 = \frac{1}{2}(x_1 + x_2) = \frac{1}{2} \left(\begin{bmatrix} 4 \\ 5 \end{bmatrix} + \begin{bmatrix} 1 \\ 4 \end{bmatrix} \right) = \begin{bmatrix} 5/2 \\ 9/2 \end{bmatrix}, \quad m_2 = \frac{1}{2}(x_3 + x_4) = \frac{1}{2} \left(\begin{bmatrix} 0 \\ 1 \end{bmatrix} + \begin{bmatrix} 5 \\ 0 \end{bmatrix} \right) = \begin{bmatrix} 5/2 \\ 1/2 \end{bmatrix}$$

$$J_1 = \|x_1 - m_1\|^2 + \|x_2 - m_1\|^2 + \|x_3 - m_2\|^2 + \|x_4 - m_2\|^2 = 18$$

$$(2) \quad m_1 = \frac{1}{2}(x_1 + x_4) = \frac{1}{2} \left(\begin{bmatrix} 4 \\ 5 \end{bmatrix} + \begin{bmatrix} 5 \\ 0 \end{bmatrix} \right) = \begin{bmatrix} 9/2 \\ 5/2 \end{bmatrix}, \quad m_2 = \frac{1}{2}(x_2 + x_3) = \frac{1}{2} \left(\begin{bmatrix} 1 \\ 4 \end{bmatrix} + \begin{bmatrix} 0 \\ 1 \end{bmatrix} \right) = \begin{bmatrix} 1/2 \\ 5/2 \end{bmatrix}$$

$$J_2 = \|x_1 - m_1\|^2 + \|x_4 - m_1\|^2 + \|x_2 - m_2\|^2 + \|x_3 - m_2\|^2 = 18$$

$$(3) \quad m_1 = \frac{1}{3}(x_1 + x_2 + x_3) = \frac{1}{3} \left(\begin{bmatrix} 4 \\ 5 \end{bmatrix} + \begin{bmatrix} 1 \\ 4 \end{bmatrix} + \begin{bmatrix} 0 \\ 1 \end{bmatrix} \right) = \begin{bmatrix} 5/3 \\ 10/3 \end{bmatrix}, \quad m_2 = x_4 = \begin{bmatrix} 5 \\ 0 \end{bmatrix}$$

$$J_3 = \|x_1 - m_1\|^2 + \|x_2 - m_1\|^2 + \|x_3 - m_1\|^2 + \|x_4 - m_2\|^2 = 17.33$$

因为: $J_3 = 17.33 < J_1 = J_2 = 18$

故, 第 3 种聚类最好

4, 现有 3 个样本: $X_1=[4, 3]^T$, $X_2=[0, 3]^T$, $X_3=[0, 0]^T$

1) 采用 K 均值算法 (误差平方和最小准则) 将其聚成 2 类, 求每类的聚类中心。要写出详细过程。

2) 若采用基于合并的分级聚类方法将上述 3 个样本聚类, 类间相似性度量采用最近距离计算, 距离阈值设为 3.5, 则算法终止时聚成几类? 要写出详细过程。

解: (1) 3 个样本, 聚成 2 类, 共有 3 种情况

1) $[X_1, X_2], [X_3]$, 聚类中心: $[2, 3]^T$, $[0, 0]^T$, 误差平方和: $J_1=8$

2) $[X_1, X_3], [X_2]$, 聚类中心: $[2, 1.5]^T$, $[0, 3]^T$, 误差平方和: $J_2=12.5$

3) $[X_2, X_3], [X_1]$, 聚类中心: $[0, 1.5]^T$, $[4, 3]^T$, 误差平方和: $J_3=4.5$

$J_1 > J_2 > J_3$ 。故: K 均值聚类结果为: $[X_2, X_3], [X_1]$, 聚类中心: $[0, 1.5]^T$, $[4, 3]^T$

(2) 因为各点距离为: $R(x_1, x_2)=4$, $R(x_2, x_3)=3$, $R(x_1, x_3)=5$,

因此, 第一次聚类: $[x_2, x_3], [x_1]$ 。距离: $R=3$

第二次聚类, 两类 $R=\min\{R(x_1, x_2)=4, R(x_1, x_3)=5\}=4 > 3.5$ 不再聚类
聚成 2 类。聚类结果: $[x_2, x_3], [x_1]$

5、现有 8 个一维数据：

$\{-5.5, -4.1, -3.0, -2.6, 10.1, 11.9, 12.6, 13.8\}$

类别相似性采用最近距离算法，即： $\Delta(\Gamma_i, \Gamma_j) = \min_{x \in \Gamma_i, y \in \Gamma_j} \{\delta(x, y)\}$ ， $\delta(x, y)$

4) 表示两个样本的距离。按基于合并的分级聚类方法画出聚类的树图。如距离阈值为 10，则算法终止时分为几个聚类？

解：此题是一维，画图计算比较简单。（实际要计算样本之间距离，然后比较大小）

1 水平，8 类，距离=0<10: **【-5.5】**, **【-4.1】**, **【-3.0】**, **【-2.6】**, **【10.1】**, **【11.9】**, **【12.6】**, **【13.8】**

2 水平，7 类，距离=0.4<10: **【-5.5】**, **【-4.1】**, **【-3.0, -2.6】**, **【10.1】**, **【11.9】**, **【12.6】**, **【13.8】**

（此时，-3.0 与-2.6 的距离为 0.4，最近。此两点合并为同一类）

3 水平，6 类，距离=0.7<10: **【-5.5】**, **【-4.1】**, **【-3.0, -2.6】**, **【10.1】**, **【11.9, 12.6】**, **【13.8】**

（此时，11.9, 12.6 的距离为 0.7，最近。此两点合并为同一类）

4 水平，5 类，距离=1.1<10: **【-5.5】**, **【-4.1, -3.0, -2.6】**, **【10.1】**, **【11.9, 12.6】**, **【13.8】**

（此时，**【-4.1】** 与 **【-3.0, -2.6】** 的最近（最近点为-3.0），距离为 1.1，最近。此两类合并为同一类）

以下步骤处理类似，不再赘述。

5 水平，4 类，距离=1.2<10: **【-5.5】**, **【-4.1, -3.0, -2.6】**, **【10.1】**, **【11.9, 12.6, 13.8】**

6 水平，3 类，距离=1.4<10: **【-5.5, -4.1, -3.0, -2.6】**, **【10.1】**, **【11.9, 12.6, 13.8】**

7 水平，2 类，距离=1.8<10: **【-5.5, -4.1, -3.0, -2.6】**, **【10.1, 11.9, 12.6, 13.8】**

8 水平，1 类，距离=12.7>10: **【-5.5, -4.1, -3.0, -2.6, 10.1, 11.9, 12.6, 13.8】**

7 水平下，距离为 1.8，小于设定阈值 10。但在 8 水平下，距离为 12.7，大于设定阈值 10。因此聚类终止时，2 个聚类。

